



低照度图像增强技术 (SCI) 分享

汇报人：余雨锚

RDD-net:ICME2023

Zero-Reference Deep Curve Estimation for Low-Light Image Enhancement

Chunle Guo^{1,2*} Chongyi Li^{1,2*} Jichang Guo^{1†}
Chen Change Loy³ Junhui Hou² Sam Kwong² Runmin Cong⁴

¹ BIIT Lab, Tianjin University ² City University of Hong Kong ³ Nanyang Technological University ⁴ Beijing Jiaotong University

{guochunle, lichongyi, jcguo}@tju.edu.cn ccloy@ntu.edu.sg

{jh.hou, cssamk}@cityu.edu.hk rmcong@bjtu.edu.cn

https://li-chongyi.github.io/Proj_Zero-DCE.html/

SCI:CVPR2022

Toward Fast, Flexible, and Robust Low-Light Image Enhancement

Long Ma^{†,§}, Tengyu Ma[†], Risheng Liu^{†,*}, Xin Fan[†], Zhongxuan Luo[†]

[†]School of Software Technology, Dalian University of Technology

[‡]DUT-RU International School of Information Science & Engineering, Dalian University of Technology

[§]Peng Cheng Laboratory

{rslu, xin.fan, zxluo}@dlut.edu.cn, {longma, matengyu}@mail.dlut.edu.cn

RDD-net:ICME2023

Full Length Article

RDD-net: Robust duplicated-diffusion watermarking based on deep network ☆



URetinex-Net:CVPR2022

URetinex-Net: Retinex-based Deep Unfolding Network for Low-light Image Enhancement

Wenhui Wu¹ Jian Weng² Pingping Zhang³ Xu Wang^{2*} Wenhan Yang⁴ Jianmin Jiang²

¹College of Electronics and Information Engineering, Shenzhen University


²College of Computer Science and Software Engineering, Shenzhen University

³Department of Computer Science, City University of Hong Kong

⁴School of Electrical and Electronic Engineering, Nanyang Technological University

■ 任务背景

- 低光照图像广泛存在于夜拍、监控、自动驾驶等场景
- 弱光图像常伴随亮度不足、细节模糊、噪声明显
- 图像质量差直接影响视觉观感和信息获取
- 工业界和学术界均高度关注该问题的解决



■ 任务需求


- 亮度增强同时保留细节
- 运行高效、轻量易部署
- 增强结果符合人眼感知习惯
- 增强后图像可用于 AI 下游任务，提升识别准确率

SCI: 一种全新的低光照增强方案



■ 技术亮点

- 提出自校准光照学习 (Self-Calibrated Illumination, SCI)
- 基于Retinex理论, 将图像分为反射与光照两部分处理
- 设计多阶段光照优化结构, 各阶段共享网络参数
- 引入自校准模块, 确保各阶段输出快速收敛一致



■ 技术优势

- 结构简单: 避免繁杂的网络设计, 仅用基础操作即可实现增强
- 推理高效: 多阶段结构在测试时可简化为单阶段, 速度显著提升
- 无监督训练: 无需成对数据, 适应性强, 泛化能力更好
- 适配多场景: 在多种真实弱光环境中均表现稳定、自然



渐进式光照估计 (Progressive Illumination Estimation)



■ 设计思路

- 根据 Retinex 理论，弱光观察 y 和想要的清晰图像 z 之间存在联系： $y = z \otimes x$ ，其中 x 表示照明分量。
- 所有阶段 (T 个阶段) 共享同一组参数 θ ，通过级联结构逐步优化光照估计，避免重复参数带来的计算冗余。
- 设计多阶段光照估计过程，每个阶段输出，通过迭代残差调整逐步逼近理想光照。 $x_{t+1} = x_t + u_t$
- 各阶段使用参数共享网络，结构简洁，易训练

■ 模块优势

- 直接学习光照与输入之间的线性残差，比端到端映射更易收敛（光照与低光观察在多数区域存在线性关系）。
- 训练更稳定，收敛更快
- 避免大模型冗余参数堆叠
- 后期可进一步通过“单阶段近似”实现快速推理

但本文提出学习残差表示 u^t ，即光照与弱光观察之间的差异

$$\mathcal{F}(x^t) : \begin{cases} u^t = \mathcal{H}_\theta(x^t), x^0 = y, \\ x^{t+1} = x^t + u^t, \end{cases}$$



自校准模块 (Self-Calibration Module)



设计动机

- 权重共享的多阶段级联可能增加推理成本，但理想情况下所有阶段应输出相似结果（即快速收敛）
- 引入自校准信号 s^t ，将每个阶段的输入与原始低光观察 y 对齐，强制各阶段输出一致。
- 引入自校准机制，融合前一阶段输出与当前输入
- 利用物理规律（Retinex）辅助收敛

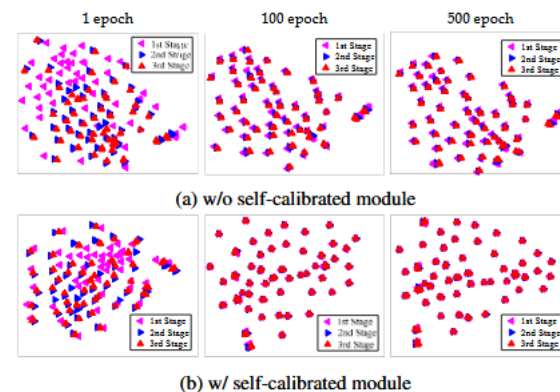
通过 s^t 校准当前输入 v^t ，使其与初始输入 y 保持差异可控。

↑

$$\mathcal{G}(x^t) : \begin{cases} z^t = y \odot x^t, \\ s^t = \mathcal{K}_{\theta}(z^t), \\ v^t = y + s^t, \end{cases}$$

模块效果

- 无自校准模块时，各阶段输出差异显著；加入后，输出快速收敛至相同分布。
- 训练时用多阶段提升性能，测试时仅需单阶段，显著加速推理。
- 增强结果更加稳定自然，细节表现更好
- 模块轻量，训练代价低，实用性强



无监督训练损失 (Unsupervised Training Loss)

■ 设计思路

- 获取真实低光照 & 高质量成对图像困难
- 有监督方法易过拟合，泛化差
- 无监督方法更灵活，适应多场景应用
- 更具实用性，可在真实场景中快速部署

$$\mathcal{L}_{total} = \alpha \mathcal{L}_f + \beta \mathcal{L}_s \quad \text{总损失}$$

$$\mathcal{L}_f = \sum_{t=1}^T \|\mathbf{x}^t - (\mathbf{y} + \mathbf{s}^{t-1})\|^2,$$

保真度损失 \mathcal{L}_f :
约束光照 \mathbf{x}^t 与校准后的输入 $\mathbf{y} + \mathbf{s}^{t-1}$ 的像素级一致性

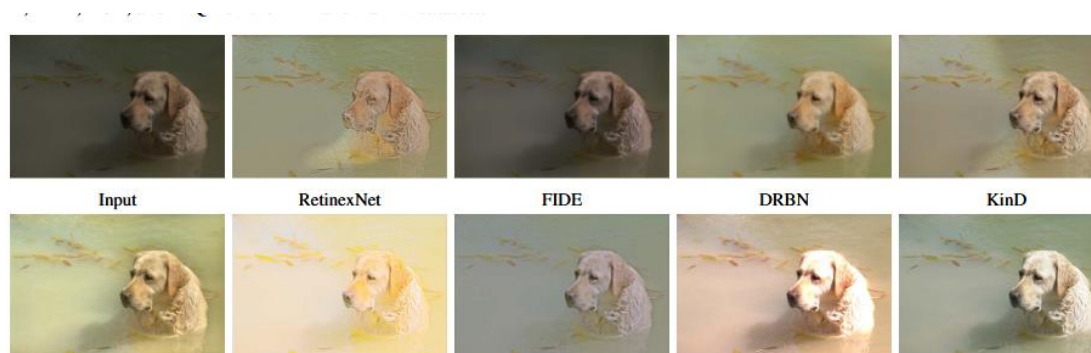
■ 模块优势

- 不依赖人工标注，通过物理关系（Retinex）自监督。
- 通过物理先验（光照平滑性）和输入一致性约束，提升模型泛化性。
- 与网络结构高度契合，训练收敛稳定

$$\mathcal{L}_s = \sum_{i=1}^N \sum_{j \in \mathcal{N}(i)} w_{i,j} |\mathbf{x}_i^t - \mathbf{x}_j^t|,$$

平滑损失 \mathcal{L}_s :
采用空间变化L1范数，强制光照平滑且保留边缘。

论文效果



实验效果

